

概率论与数理统计笔记

刘承杰

南京大学软件学院

2021 年 8 月 14 日

目录

1	概率论的基本概念	1
1.1	随机试验	1
1.2	样本空间、随机事件	1
1.3	频率与概率	2
1.4	等可能概型（古典概型）	3
1.5	条件概率	3
1.6	独立性	4
2	随机变量及其分布	5
2.1	随机变量	5
2.2	离散型随机变量及其分布律	5
2.3	随机变量的分布函数	5
2.4	连续型随机变量及其概率密度	6
2.5	随机变量的函数的分布	7
3	多维随机变量及其分布	8
3.1	二维随机变量	8
3.2	边缘分布	8

3.3	条件分布	9
3.4	相互独立的随机变量	9
3.5	两个随机变量的函数的分布	10
4	随机变量的数字特征	12
4.1	数学期望	12
4.2	方差	13
4.3	协方差及相关系数	14
4.4	矩、协方差矩阵	15
5	大数定律及中心极限定理	16
5.1	大数定律	16
5.2	中心极限定理	16
6	样本及抽样分布	19
6.1	随机样本	19
6.2	直方图和箱线图	19
6.3	抽样分布	19
7	参数估计	24
7.1	点估计	24
7.2	估计量的评选标准	26
8	假设检验	27
8.1	假设检验	27
9	方差分析及回归分析	28
9.1	单因素试验的方差分析	28

1 概率论的基本概念

1.1 随机试验

定义 1.1 (随机试验) 在概率论中, 我们将具有以下三个特点的试验称为随机试验:

1. 可以在相同的条件下重复的进行;
2. 每次试验的可能结果不止一个, 并且能事先明确试验的所有可能结果;
3. 进行一次试验之前不能确定哪个结果会出现

1.2 样本空间、随机事件

定义 1.2 (样本空间) 随机事件 E 的所有可能结果组成的集合, 记为 S

定义 1.3 (样本点) 样本空间的元素, 即 E 的每个结果

定义 1.4 (随机事件) 试验 E 的样本空间 S 的子集为 E 的随机事件, 简称事件. 在每次试验中, 当且仅当这一子集中的一个样本点出现时, 称这一事件发生

定义 1.5 (基本事件) 由一个样本点组成的单点集, 称为基本事件

定义 1.6 (必然事件和不可能事件) 样本空间 S 包含所有的样本点, 它是 S 自身的子集, 在每次试验中它总是发生的, S 称为 **必然事件**. 空集 \emptyset 不包含任何样本点, 它也作为样本空间的子集, 它在每次试验中都不可能发生, \emptyset 称为**不可能事件**.

定义 1.7 (事件间的关系与事件的运算) 设试验 E 的样本空间为 S , 而 $A, B, A_k (k = 1, 2, \dots)$ 是 S 的子集.

1. 若 $A \subset B$, 则称事件 B 包含事件 A , 这指的是事件 A 发生, 则事件 B 必然发生. 若 $A \subset B$ 且 $B \subset A$, 即 $A = B$, 则称事件 A 与事件 B 相等。

2. 事件 $A \cup B = \{x | x \in A \text{ 或 } x \in B\}$ 称为事件 A 与事件 B 的**和事件**。当且仅当 A, B 中至少有一个发生时, 事件 $A \cup B$ 发生。

类似地, 称 $\bigcup_{k=1}^n A_k$ 为 n 个事件 A_1, A_2, \dots, A_n 的**和事件**; 称 $\bigcup_{k=1}^{\infty} A_k$ 为可列个事件 A_1, A_2, \dots 的**和事件**

3. 事件 $A \cap B = \{x | x \in A \text{ 且 } x \in B\}$ 称为事件 A 与事件 B 的**积事件**。当且仅当 A, B 同时发生时, 事件 $A \cap B$ 发生。

类似地, 称 $\bigcap_{k=1}^n A_k$ 为 n 个事件 A_1, A_2, \dots, A_n 的**积事件**; 称 $\bigcap_{k=1}^{\infty} A_k$ 为可列个事件 A_1, A_2, \dots 的**积事件**

4. 事件 $A - B = \{x | x \in A \text{ 且 } x \notin B\}$ 称为事件 A 与事件 B 的**差事件**。当且仅当 A 发生、 B 不发生时事件 $A - B$ 发生。

5. 若 $A \cap B = \emptyset$, 则称事件 A 与 B 是互不相容的, 或**互斥的**。这指的是事件 A 与 B 不能同时发生。基本事件是两两互不相容的。

6. 若 $A \cup B = S$ 且 $A \cap B = \emptyset$, 则称事件 A 与事件 B 互为逆事件, 又称事件 A 与事件 B 互为对立事件。这指的是对每次试验而言, 事件 A 、 B 中必有一个发生, 且仅有一个发生。 A 的对立事件记为 \bar{A}

定理 1.1 (集合运算定律) 设 A 、 B 、 C 为事件, 则有:

交换律:

$$A \cup B = B \cup A$$

$$A \cap B = B \cap A$$

结合律:

$$A \cup (B \cap C) = (A \cup B) \cap C$$

$$A \cap (B \cup C) = (A \cap B) \cup C$$

分配律:

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$$

德摩根律:

$$\overline{A \cup B} = \bar{A} \cap \bar{B}$$

$$\overline{A \cap B} = \bar{A} \cup \bar{B}$$

1.3 频率与概率

定义 1.8 (频率) 在相同的条件下, 进行了 n 次试验, 在这 n 次试验中, 事件 A 发生的次数 n_A 称为事件 A 发生的频数。比值 $\frac{n_A}{n}$ 称为事件 A 发生的频率, 并记为 $f_n(A)$ 。

定义 1.9 (概率) 设 E 是随机试验, S 是它的样本空间, 对于 E 的每一个事件 A 赋予一个实数, 记为 $P(A)$, 称为事件 A 的概率, 如果集合函数 $P(\cdot)$ 满足下列条件:

1. 非负性: 对于每一个事件 A , 有 $P(A) \geq 0$;
2. 规范性: 对于必然事件 S , 有 $P(S) = 1$;
3. 可列可加性: 设 A_1, A_2, \dots 是两两不相容的事件, 即对于 $A_i A_j = \emptyset, i \neq j, i, j = 1, 2, \dots$, 有

$$P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$$

当 $n \rightarrow \infty$ 时频率 $f_n(A)$ 在一定意义下接近于概率 $P(A)$

1.4 等可能概型（古典概型）

定义 1.10 (等可能概型) 具有以下两个特点的试验称为等可能概型：

1. 试验的样本空间只包含有限个元素；
2. 试验中每个基本事件发生的可能性相同。

定理 1.2 (等可能概型中事件A的概率计算公式) 若事件A包含K个基本事件，即 $A = e_{i_1} \cup e_{i_2} \cup \dots \cup e_{i_k}$ ，这里 i_1, i_2, \dots, i_k 是 $1, 2, \dots, n$ 中某 k 个不同的数，则有：

$$P(A) = \sum_{j=1}^k P(\{e_{i_j}\}) = \frac{k}{n} = \frac{A \text{ 包含的基本事件数}}{S \text{ 中基本事件的总数}}$$

定理 1.3 (超几何分布的概率公式) 设共有 N 件产品，其中有 D 件次品，从中取 n 件，其中恰好有 $k (k \leq D)$ 件次品的概率为：

$$p = \frac{\binom{D}{k} \binom{N-D}{n-k}}{\binom{N}{n}}$$

1.5 条件概率

定义 1.11 (条件概率) 设 A, B 是两个事件，且 $P(A) > 0$ ，称

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为在事件 A 发生的条件下事件 B 发生的条件概率。

定理 1.4 (乘法定理) 设 $P(A) > 0$ ，则有

$$P(AB) = P(B|A)P(A)$$

上式可以推广到多个事件的积事件的情况。例如，设 A, B, C 为事件，且 $P(AB) > 0$ ，则有

$$P(ABC) = P(C|AB)P(B|A)P(A)$$

一般地，设 A_1, A_2, \dots, A_n 为 n 个事件， $n \geq 2$ ，且 $P(A_1 A_2 \dots A_{n-1}) > 0$ ，则有

$$P(A_1 A_2 \dots A_n) = P(A_n | A_1 A_2 \dots A_{n-1}) P(A_{n-1} | A_1 A_2 \dots A_{n-2}) \dots P(A_2 | A_1) P(A_1)$$

定义 1.12 (样本空间的划分) 设 S 为试验 E 的样本空间， B_1, B_2, \dots, B_n 为 E 的一组事件，若

1. $B_i B_j = \emptyset, i \neq j, i, j = 1, 2, \dots, n$
2. $B_1 \cup B_2 \cup \dots \cup B_n = S$

则称 B_1, B_2, \dots, B_n 为样本空间的一个划分。

若 B_1, B_2, \dots, B_n 为样本空间的一个划分，那么对于每次试验，事件 B_1, B_2, \dots, B_n 中必有且只有一个发生。

定理 1.5 (全概率公式) 设试验 E 的样本空间为 S , A 为 E 的事件, B_1, B_2, \dots, B_n 为 S 的一个划分, 且 $P(B_i) > 0, i = 1, 2, \dots, n$, 则

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$$

定理 1.6 (贝叶斯(Bayes)公式) 设试验 E 的样本空间为 S , A 为 E 的事件, B_1, B_2, \dots, B_n 为 S 的一个划分, 且 $P(A) > 0, P(B_i) > 0, i = 1, 2, \dots, n$, 则

$$P(B_i|A) = \frac{P(B_iA)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}, i = 1, 2, \dots, n$$

1.6 独立性

定义 1.13 (独立性) 设 A, B 是两事件, 如果满足等式

$$P(AB) = P(A)P(B)$$

则称事件 A, B 相互独立

同理, 对于 A, B, C 三个事件, 如果满足等式

$$P(AB) = P(A)P(B)$$

$$P(BC) = P(B)P(C)$$

$$P(AC) = P(A)P(C)$$

$$P(ABC) = P(A)P(B)P(C)$$

则称事件 A, B, C 相互独立。

一般地, 设 A_1, A_2, \dots, A_n 是 $n(n \geq 2)$ 个事件, 如果对于其中任意2个, 任意3个, \dots , 任意 n 个事件的积事件的概率都等于各事件概率的积, 则称事件 A_1, A_2, \dots, A_n 相互独立。

2 随机变量及其分布

2.1 随机变量

定义 2.1 (随机变量) 设随机试验的样本空间为 $S = \{e\}$, $X = X(e)$ 是定义在样本空间 S 上的实值单值函数, 称 $X = X(e)$ 为随机变量

2.2 离散型随机变量及其分布律

定义 2.2 (离散型随机变量) 全部可能取到的值是有限个或可列无限多个的随机变量, 称为离散型随机变量。

定义 2.3 ((0-1)分布) 设随机变量 X 只能取 0, 1 两个值, 它的分布律是

$$P\{X = k\} = p^k(1-p)^{1-k}, k = 0, 1 \quad (0 < p < 1)$$

定义 2.4 (伯努利试验) 设试验 E 只有两个可能结果: A 和 \bar{A} , 则称 E 为伯努利(Bernoulli)试验. 设 $P(A) = p$ ($0 < p < 1$), 此时 $P(\bar{A}) = 1 - p$, 将 E 独立重复进行 n 次, 则称这一串重复的独立试验为 n 重伯努利试验。

定义 2.5 (二项分布) 以 X 表示 n 重伯努利试验中事件 A 发生的次数, 事件 A 在指定的 k ($0 \leq k \leq n$) 次试验中发生的概率为

$$P\{X = k\} = \binom{n}{k} p^k (1-p)^{n-k}, k = 0, 1, 2, \dots, n$$

随机变量 X 服从参数为 n, p 的二项分布, 并记为 $X \sim b(n, p)$ 。

定义 2.6 (泊松分布) 设随机变量 X 所有可能取的值为 $0, 1, 2, \dots$, 而取各个值的概率为

$$P\{X = k\} = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, \dots,$$

其中 $\lambda > 0$ 是常数。则称 X 服从参数为 λ 的泊松分布, 记为 $X \sim \pi(\lambda)$

定理 2.1 (泊松定理) 设 $\lambda > 0$ 是一个常数, n 是任意正整数, 设 $np_n = \lambda$, 则对于任一固定的非负整数 k , 有

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1-p_n)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}$$

2.3 随机变量的分布函数

定义 2.7 (随机变量的分布函数) 设 X 是一个随机变量, x 是任意实数, 函数

$$F(X) = P\{X \leq x\}, -\infty < x < \infty$$

称为 X 的分布函数

定理 2.2 (分布函数性质)

1. $F(x)$ 是一个不减函数
2. $0 \leq x \leq 1$, 且 $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1$
3. $F(x+0) = F(x)$, 即 $F(x)$ 是右连续的

反之, 具备上述三条性质的函数必是某个随机变量的分布函数。

2.4 连续型随机变量及其概率密度

定义 2.8 (连续型随机变量、概率密度) 如果对于随机变量 X 的分布函数 $F(x)$, 存在非负可积函数 $f(x)$, 使对于任意实数 x 有

$$F(x) = \int_{-\infty}^x f(t) dt$$

则称 X 为连续型随机变量, $f(x)$ 称为 X 的概率密度函数, 简称概率密度。

定义 2.9 (均匀分布) 若连续型随机变量 X 具有概率密度

$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其他} \end{cases}$$

则称 X 在区间 (a, b) 上服从均匀分布, 记为 $X \sim U(a, b)$

X 的分布函数为

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x < b \\ 1, & x \geq b \end{cases}$$

定义 2.10 (指数分布) 若连续型随机变量 X 的概率密度为

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & \text{其他} \end{cases}$$

其中 $\theta > 0$ 为常数, 则称 X 服从参数为 θ 的指数分布

X 的分布函数为

$$F(x) = \begin{cases} 1 - e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & \text{其他} \end{cases}$$

定义 2.11 (正态分布) 若连续型随机变量 X 的概率密度为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty$$

其中 $\mu, \sigma (\sigma > 0)$ 为常数, 则称 X 服从参数为 μ, σ 的正态分布或高斯分布, 记为 $X \sim N(\mu, \sigma^2)$

X 的分布函数为

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$$

特别地, 当 $\mu = 0, \sigma = 1$ 时, 称随机变量 X 服从标准正态分布, 其概率密度和分布函数分别用 $\varphi(x), \Phi(x)$ 表示, 有

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

对于一般的正态分布, 只需通过一个线性变换就能化为标准正态分布:

$$\text{若 } X \sim N(\mu, \sigma^2), \text{ 则 } Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

2.5 随机变量的函数的分布

定理 2.3 设随机变量 X 具有概率密度 $f_x(x), -\infty < x < \infty$, 又设函数 $g(x)$ 处处可导且恒有 $g'(x) > 0$ (或恒有 $g'(x) < 0$, 则 $Y = g(X)$ 是连续型随机变量, 其概率密度为

$$f_Y(y) = \begin{cases} f_x[h(y)]|h'(y)|, & \alpha < y < \beta \\ 0, & \text{其他} \end{cases}$$

其中 $\alpha = \min\{g(-\infty), g(\infty)\}, \beta = \max\{g(-\infty), g(\infty)\}, h(y)$ 是 $g(x)$ 的反函数

3 多维随机变量及其分布

3.1 二维随机变量

定义 3.1 (联合分布函数) 设 (X, Y) 是二维随机变量, 对于任意实数 x, y , 二元函数

$$F(x, y) = P\{(X \leq x) \cap (Y \leq y)\} \equiv P\{X \leq x, Y \leq y\}$$

称为二维随机变量 (X, Y) 的分布函数, 或称为随机变量 X 和 Y 的联合分布函数。

如果将二维随机变量 (X, Y) 看成是平面上随机点的坐标, 那么分布函数 $F(x, y)$ 在 (x, y) 处的函数值就是随机点 (X, Y) 落在以点 (x, y) 为顶点而位于该点左下方的无穷矩形区域内的概率。

所以, 随机点 (X, Y) 落在矩形区域 $\{(x, y) | x_1 < x \leq x_2, y_1 < y \leq y_2\}$ 的概率为

$$P\{x_1 < x \leq x_2, y_1 < y \leq y_2\} = F(x_2, y_2) - F(x_2, y_1) + F(x_1, y_1) - F(x_1, y_2)$$

定义 3.2 (联合概率密度) 对于二维随机变量 (X, Y) 的分布函数 $F(x, y)$, 如果存在非负可积函数 $f(x, y)$ 使对于任意 x, y 有

$$F(x, y) = \int_{-\infty}^y \int_{-\infty}^x f(u, v) du dv$$

则称 (X, Y) 是连续型的二维随机变量, 函数 $f(x, y)$ 称为二维随机变量 (X, Y) 的概率密度, 或称为随机变量 X 和 Y 的联合概率密度。

3.2 边缘分布

定义 3.3 (边缘分布函数) 二维随机变量 (X, Y) 作为一个整体, 具有分布函数 $F(x, y)$, 而 X 和 Y 都是随机变量, 各自也有分布函数, 将他们分别记为 $F_X(x), F_Y(y)$, 依次称为二维随机变量 (X, Y) 关于 X 和关于 Y 的边缘分布函数, 且

$$F_X(x) = F(x, \infty), F_Y(y) = F(\infty, y)$$

定义 3.4 (边缘分布律) 记

$$p_{i\cdot} = \sum_{j=1}^{\infty} p_{ij} = P\{X = x_i\}, \quad i = 1, 2, \dots,$$
$$p_{\cdot j} = \sum_{i=1}^{\infty} p_{ij} = P\{Y = y_j\}, \quad j = 1, 2, \dots,$$

分别称 $p_{i\cdot} (i = 1, 2, \dots)$ 和 $p_{\cdot j} (j = 1, 2, \dots)$ 为 (X, Y) 关于 X 和 Y 的边缘分布律

定义 3.5 (边缘概率密度) 记

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$
$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

分别称 $f_X(x), f_Y(y)$ 为 (X, Y) 关于 X 和 Y 的边缘概率密度。

3.3 条件分布

定义 3.6 (条件分布律) 设 (X, Y) 是二维离散型随机变量, 对于固定的 j , 若 $P\{Y = y_j\} > 0$, 则称

$$P\{X = x_i | Y = y_j\} = \frac{P\{X = x_i, Y = y_j\}}{P\{Y = y_j\}} = \frac{p_{ij}}{p_{\cdot j}}, i = 1, 2, \dots$$

为在 $Y = y_j$ 条件下随机变量 X 的条件分布律

同样, 对于固定的 i , 若 $P\{X = x_i\} > 0$, 则称

$$P\{Y = y_j | X = x_i\} = \frac{P\{X = x_i, Y = y_j\}}{P\{X = x_i\}} = \frac{p_{ij}}{p_{i \cdot}}, j = 1, 2, \dots$$

为在 $X = x_i$ 条件下随机变量 Y 的条件分布律

定义 3.7 (条件概率密度) 设二维随机变量 (X, Y) 的概率密度为 $f(x, y)$, (X, Y) 关于 Y 的边缘概率密度为 $f_Y(y)$. 若对于固定的 y , $f_Y(y) > 0$, 则称 $\frac{f(x, y)}{f_Y(y)}$ 为在 $Y = y$ 的条件下 X 的条件概率密度, 记为

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$

称 $\int_{-\infty}^x f_{X|Y}(x|y) dx = \int_{-\infty}^x \frac{f(x, y)}{f_Y(y)} dx$ 为在 $Y = y$ 的条件下 X 的条件分布函数, 记为 $P\{X \leq x | Y = y\}$ 或 $F_{X|Y}(x|y)$, 即

$$F_{X|Y}(x|y) = P\{X \leq x | Y = y\} = \int_{-\infty}^x \frac{f(x, y)}{f_Y(y)} dx$$

类似地, 可以定义 $f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$ 和 $F_{Y|X}(y|x) = \int_{-\infty}^y \frac{f(x, y)}{f_X(x)} dy$

3.4 相互独立的随机变量

定义 3.8 (相互独立) 若对于所有 x, y , 满足下列条件之一, 则称随机变量 X 和 Y 是相互独立的:

1. 设 $F(x, y)$ 及 $F_X(x), F_Y(y)$ 分别是二维随机变量 (X, Y) 的分布函数及边缘分布函数, 有

$$F(x, y) = F_X(x)F_Y(y)$$

2. 设 $f(x, y), f_X(x), f_Y(y)$ 分别为 (X, Y) 的概率密度和边缘概率密度, 有

$$f(x, y) = f_X(x)f_Y(y)$$

3. 当 X, Y 是离散型随机变量是, 对于 (X, Y) 的所有可能取值 (x_i, y_i) , 有

$$P\{X = x_i, Y = y_i\} = P\{X = x_i\}P\{Y = y_i\}$$

定理 3.1 设 (X_1, X_2, \dots, X_m) 和 (Y_1, Y_2, \dots, Y_n) 相互独立, 则 $X_i (i = 1, 2, \dots, m)$ 和 $Y_j (j = 1, 2, \dots, n)$ 相互独立. 又若 h, g 是连续函数, 则 $h(X_1, X_2, \dots, X_m)$ 和 $g(Y_1, Y_2, \dots, Y_n)$ 相互独立.

3.5 两个随机变量的函数的分布

定义 3.9 ($Z = X + Y$ 分布) 设 (X, Y) 是二维连续型随机变量, 它具有概率密度 $f(x, y)$, 则 $Z = X + Y$ 仍为连续型随机变量, 其概率密度为

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f(z-y, y) dy, \quad (1)$$

或

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f(x, z-x) dx. \quad (2)$$

又若 X 和 Y 相互独立, 设 (X, Y) 关于 X, Y 的边缘密度分别为 $f_X(x), f_Y(y)$, 则(1),(2)分别可化为

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f_X(z-y) f_Y(y) dy$$

和

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx$$

这两个公式称为 f_X 和 f_Y 的卷积公式, 记为 $f_X * f_Y$, 即

$$f_X * f_Y = \int_{-\infty}^{\infty} f_X(z-y) f_Y(y) dy = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx$$

定理 3.2 有限个相互独立的正态随机变量的线性组合仍然服从正态分布

定义 3.10 ($Z = \frac{Y}{X}$ 分布、 $Z = XY$ 的分布) 设 (X, Y) 是二维连续型随机变量, 它具有概率密度 $f(x, y)$, 则 $Z = \frac{Y}{X}, Z = XY$ 仍为连续型随机变量, 其概率密度分别为

$$f_{Y/X}(z) = \int_{-\infty}^{\infty} |x| f(x, xz) dx; \quad (3)$$

$$f_{XY}(z) = \int_{-\infty}^{\infty} \frac{1}{|x|} f(x, \frac{z}{x}) dx. \quad (4)$$

又若 X 和 Y 相互独立, 设 (X, Y) 关于 X, Y 的边缘密度分别为 $f_X(x), f_Y(y)$, 则(3)可化为

$$f_{Y/X}(z) = \int_{-\infty}^{\infty} |x| f_X(x) f_Y(xz) dx$$

(4)可化为

$$f_{XY}(z) = \int_{-\infty}^{\infty} \frac{1}{|x|} f_X(x) f_Y(\frac{z}{x}) dx$$

定义 3.11 ($M = \max\{X, Y\}$ 分布及 $N = \min\{X, Y\}$ 分布) 设 X, Y 是两个相互独立的随机变量, 它们的分布函数分别为 $F_X(x)$ 和 $F_Y(y)$, 可得 $M = \max\{X, Y\}$ 的分布函数为

$$F_{\max}(z) = F_X(z) F_Y(z)$$

类似地，可得到 $N = \min\{X, Y\}$ 的分布函数为

$$F_{\min}(z) = 1 - [1 - F_X(z)][1 - F_Y(z)]$$

以上结果容易推广到 n 个相互独立的随机变量的情况。设 X_1, X_2, \dots, X_n 是 n 个相互独立的随机变量，它们的分布函数分别为 $F_{X_i}(x_i) (i = 1, 2, \dots, n)$ ，则 $M = \max\{X_1, X_2, \dots, X_n\}$ 及 $N = \min\{X_1, X_2, \dots, X_n\}$ 的分布函数分别为

$$F_{\max}(z) = F_{X_1}(z)F_{X_2}(z) \cdots F_{X_n}(z)$$

$$F_{\min}(z) = 1 - [1 - F_{X_1}(z)][1 - F_{X_2}(z)] \cdots [1 - F_{X_n}(z)]$$

特别地，当 X_1, X_2, \dots, X_n 相互独立且具有相同分布函数 $F(x)$ 时有

$$F_{\max}(z) = [F(z)]^n$$

$$F_{\min}(z) = 1 - [1 - F(z)]^n$$

4 随机变量的数字特征

4.1 数学期望

定义 4.1 (数学期望) 设离散型随机变量 X 的分布律为 $P\{X = x_k\}, k = 1, 2, \dots$. 若级数 $\sum_{k=1}^{\infty} x_k p_k$ 绝对收敛, 则称级数 $\sum_{k=1}^{\infty} x_k p_k$ 的和为随机变量 X 的数学期望, 记为 $E(X)$, 即

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

设连续型随机变量 X 的概率密度为 $f(x)$, 若积分 $\int_{-\infty}^{\infty} x f(x) dx$ 绝对收敛, 则称积分 $\int_{-\infty}^{\infty} x f(x) dx$ 的值为随机变量 X 的数学期望, 记为 $E(X)$, 即

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

数学期望 $E(X)$ 完全由随机变量 X 的概率分布所确定。

定理 4.1 设 Y 是随机变量 X 的函数: $Y = g(X)$ (g 是连续函数)

(i) 如果 X 是离散型随机变量, 它的分布律为 $P = \{X = x_k\} = p_k, k = 1, 2, \dots$, 若 $\sum_{k=1}^{\infty} g(x_k) p_k$ 绝对收敛, 则有

$$E(Y) = E[g(x)] = \sum_{k=1}^{\infty} g(x_k) p_k$$

(ii) 如果 X 是连续型随机变量, 它的概率密度为 $f(x)$, 若 $\int_{-\infty}^{\infty} g(x) f(x) dx$ 绝对收敛, 则有

$$E(Y) = E[g(x)] = \int_{-\infty}^{\infty} g(x) f(x) dx$$

上述定理还可以推广到两个或两个以上随机变量的函数的情况。

例如设 Z 是随机变量 X, Y 的函数 $Z = g(X, Y)$ (g 是连续函数), 那么, Z 是一个一维随机变量。若二维随机变量 (X, Y) 的概率密度为 $f(x, y)$, 则有

$$E(Z) = E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy$$

这里设上式右边的积分绝对收敛。又若 (X, Y) 为离散型随机变量, 其分布律为 $P = \{X = x_i, Y = y_j\} = p_{ij}, i, j = 1, 2, \dots$, 则有

$$E(Z) = E[g(X, Y)] = \sum_{j=1}^{\infty} \sum_{i=1}^{\infty} g(x_i, y_j) p_{ij}$$

这里设上式右边的级数绝对收敛。

定理 4.2 数学期望的性质:

1° 设 C 是常数, 则有 $E(C) = C$

2° 设 X 是一个随机变量, C 是常数, 则有

$$E(CX) = CE(X)$$

3° 设 X, Y 是两个随机变量, 则有

$$E(X + Y) = E(X) + E(Y)$$

这一性质可以推广到任意有限个随机变量之和的情况

4° 设 X, Y 是两个相互独立的随机变量, 则有

$$E(XY) = E(X)E(Y)$$

这一性质可以推广到任意有限个相互独立的随机变量之积的情况

4.2 方差

定义 4.2 (方差) 设 X 是一个随机变量, 若 $E\{[X - E(X)]^2\}$ 存在, 则称 $E\{[X - E(X)]^2\}$ 为 X 的方差, 记为 $D(X)$ 或 $\text{Var}(X)$, 即

$$D(X) = \text{Var}(X) = E\{[X - E(X)]^2\}$$

在应用上还引入量 $\sqrt{D(X)}$, 记为 $\sigma(X)$, 称为标准差或均方差。

对于离散型随机变量, 有

$$D(X) = \sum_{k=1}^{\infty} [x_k - E(X)]^2 p_k$$

其中 $P = \{X = x_k\} = p_k, k = 1, 2, \dots$ 是 X 的分布律

对于连续型随机变量, 有

$$D(X) = \int_{-\infty}^{\infty} [x - E(X)]^2 f(x) dx$$

其中 $f(x)$ 是 X 的概率密度

随机变量 X 的方差可按下列公式计算

$$D(X) = E(X^2) - [E(X)]^2$$

定理 4.3 方差的性质:

1° 设 C 是常数, 则 $D(C) = 0$

2° 设 X 是随机变量, C 是常数, 则有

$$D(CX) = C^2 D(X) \quad D(X + C) = D(X)$$

3° 设 X, Y 是两个随机变量, 则有

$$D(X + Y) = D(X) + D(Y) + 2E\{[X - E(X)][Y - E(Y)]\}$$

特别地, 若 X, Y 相互独立, 则有

$$D(X + Y) = D(X) + D(Y)$$

这一性质可以推广到任意有限多个相互独立的随机变量之和的情况

4° $D(X) = 0$ 的充要条件是 X 以概率1取常数 $E(X)$, 即

$$P\{X = E(X)\} = 1$$

定理 4.4 (切比雪夫(Chebyshev)不等式) 设随机变量 X 具有数学期望 $E(X) = \mu$, 方差 $D(X) = \sigma^2$, 则对于任意整数 ε , 有不等式

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$$

也可写为

$$P\{|X - \mu| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2}$$

4.3 协方差及相关系数

定义 4.3 (协方差、相关系数) 量 $E\{[X - E(X)][Y - E(Y)]\}$ 称为随机变量 X 与 Y 的协方差, 记为 $\text{Cov}(X, Y)$, 即

$$\text{Cov}(X, Y) = E\{[X - E(X)][Y - E(Y)]\}$$

而

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

称为随机变量的 X 和 Y 的相关系数。

协方差的计算公式:

$$D(X + Y) = D(X) + D(Y) + 2\text{Cov}(X, Y) \quad \text{Cov} = E(X, Y) - E(X)E(Y)$$

定理 4.5 协方差的性质:

1. $\text{Cov}(aX, bY) = ab\text{Cov}(X, Y)$, a, b 是常数;
2. $\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$

定理 4.6 ρ_{XY} 的性质:

1. $|\rho_{XY}| \leq 1$
2. $|\rho_{XY}| = 1$ 的充要条件是, 存在常数 a, b , 使得 $P\{Y = a + bX\} = 1$

ρ_{XY} 是一个可以用来表征 X, Y 之间线性关系紧密程度的量, 当 $|\rho_{XY}|$ 较大时, X, Y 线性相关程度较好, 当 $|\rho_{XY}|$ 较小时, X, Y 线性相关程度较差, 当 $|\rho_{XY}| = 0$ 时, 称 X 和 Y 不相关。

4.4 矩、协方差矩阵

定义 4.4 设 X 和 Y 是随机变量。

若

$$E(X^k) \quad k = 1, 2, \dots$$

存在, 则称它为 X 的 k 阶原点矩, 简称 k 阶矩。

若

$$E\{[X - E(X)]^k\} \quad k = 2, 3, \dots$$

存在, 则称它为 X 的 k 阶中心矩。

若

$$E\{[X - E(X)]^k[Y - E(Y)]^l\} \quad k, l = 1, 2, \dots$$

存在, 则称它为 X 和 Y 的 $k + l$ 阶混合中心矩。

定义 4.5 (协方差矩阵) 先以二维随机变量为例。二维随机变量 (X_1, X_2) 有四个二阶中心矩 (设它们都存在), 分别记为

$$c_{11} = E\{[X_1 - E(X_1)]^2\}$$

$$c_{12} = E\{[X_1 - E(X_1)][X_2 - E(X_2)]\}$$

$$c_{21} = E\{[X_2 - E(X_2)][X_1 - E(X_1)]\}$$

$$c_{22} = E\{[X_2 - E(X_2)]^2\}$$

将它们排成矩阵的形式

$$\begin{pmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{pmatrix}$$

这个矩阵称为随机变量 (X_1, X_2) 的协方差矩阵。

设 n 维随机变量 (X_1, X_2, \dots, X_n) 的二阶混合中心矩 $c_{ij} = \text{Cov}(X_i, X_j) = E\{[X_i - E(X_i)][X_j - E(X_j)]\}, i, j = 1, 2, \dots, n$ 都存在, 则称矩阵

$$C = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}$$

为 n 维随机变量 (X_1, X_2, \dots, X_n) 的协方差矩阵, 该矩阵是一个对称矩阵。

5 大数定律及中心极限定理

5.1 大数定律

定理 5.1 (弱大数定律(辛钦大数定律)) 设 X_1, X_2, \dots 是相互独立的, 服从同一分布的随机变量序列, 且具有数学期望 $E(X_k) = \mu (k = 1, 2, \dots)$ 。作前 n 个变量的算数平均 $\frac{1}{n} \sum_{k=1}^n X_k$, 则对于任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| < \varepsilon \right\} = 1$$

定义 5.1 设 $Y_1, Y_2, \dots, Y_n, \dots$ 是一个随机变量序列, a 是一个常数。若对于任意正数 ε , 有

$$\lim_{n \rightarrow \infty} P \{ |Y_n - a| < \varepsilon \} = 1$$

则称序列 $Y_1, Y_2, \dots, Y_n, \dots$ 依概率收敛于 a , 记为

$$Y_n \xrightarrow{P} a$$

定理 5.2 (弱大数定律(辛钦大数定律)) 设随机变量 X_1, X_2, \dots 相互独立, 服从同一分布, 且具有数学期望 $E(X_k) = \mu (k = 1, 2, \dots)$, 则序列 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛于 μ , 即 $\bar{X} \xrightarrow{P} a$

定理 5.3 (伯努利大数定律) 设 f_A 是 n 次独立重复试验中事件 A 发生的次数, p 是事件 A 在每次试验中发生的概率, 则对于任意正数 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{f_A}{n} - p \right| < \varepsilon \right\} = 1$$

或

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{f_A}{n} - p \right| \geq \varepsilon \right\} = 0$$

5.2 中心极限定理

定理 5.4 (独立同分布的中心极限定理) 设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, 服从同一分布, 且具有数学期望和方差: $E(X_k) = \mu, D(X_k) = \sigma^2 > 0 (k = 1, 2, \dots)$, 则随机变量之和 $\sum_{k=1}^n X_k$ 的标准化变量

$$Y_n = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$$

的分布函数 $F_n(x)$ 对于任意 x 满足

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

评论 该定理表明, 均值为 μ , 方差为 $\sigma^2 > 0$ 的独立同分布的随机变量 X_1, X_2, \dots, X_n 之和 $\sum_{k=1}^n X_k$ 的标准化变量, 当 n 充分大时, 有

$$\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \sim N(0, 1)$$

也可改写为

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) \quad \text{或} \quad \bar{X} \sim N(\mu, \sigma^2/n)$$

定理 5.5 (李雅普诺夫(Lyapunov)定理) 设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, 它们具有数学期望和方差 $E(X_k) = \mu, D(X_k) = \sigma_k^2 > 0, k = 1, 2, \dots$, 记 $B_n^2 = \sum_{k=1}^n \sigma_k^2$ 。若存在整数 δ , 使得当 $n \rightarrow \infty$ 时,

$$\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{|X_k - \mu_k|^{2+\delta}\} \rightarrow 0,$$

则随机变量之和 $\sum_{k=1}^n X_k$ 的标准化变量

$$Z_n = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n}$$

的分布函数 $F_n(x)$ 对任意 x , 满足

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

评论 该定理表明, 在定理的条件下, 随机变量

$$Z_n = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n}$$

当 n 很大时, 近似地服从正态分布 $N(0, 1)$ 。由此, 当 n 很大时, $\sum_{k=1}^n X_k = B_n Z_n + \sum_{k=1}^n \mu_k$ 近似地

服从正态分布 $N(\sum_{k=1}^n \mu_k, B_n^2)$ 。这也就是说, 无论各个随机变量 $X_k (k = 1, 2, \dots)$ 服从什么分布,

只要满足定理的条件, 那么它们的和 $\sum_{k=1}^n X_k$ 当 n 很大时, 就近似地服从正态分布。

定理 5.6 (棣莫弗-拉普拉斯(De Moivre-Laplace)定理) 设随机变量 $\eta_n (n = 1, 2, \dots)$ 服从参数为 $n, p (0 < p < 1)$ 的二项分布, 则对于任意 x , 有

$$\lim_{n \rightarrow \infty} P \left\{ \frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

评论 该定理表明，正态分布是二项分布的极限分布。当 n 充分大时，可以用该定理计算二项分布的概率。

6 样本及抽样分布

6.1 随机样本

定义 6.1 设 X 是具有分布函数 F 的随机变量, 若 X_1, X_2, \dots, X_n 是具有同一分布函数 F 的、相互独立的随机变量, 则称 X_1, X_2, \dots, X_n 为从分布函数 F (或总体 F 、或总体 X) 得到的容量为 n 的简单随机样本, 简称样本, 它们的观察值 x_1, x_2, \dots, x_n 称为 样本值, 又称为 X 的 n 个独立的观察值。

由定义得: 若 X_1, X_2, \dots, X_n 为 F 的一个样本, 则 X_1, X_2, \dots, X_n 相互独立, 且它们的分布函数都是 F , 所以 (X_1, X_2, \dots, X_n) 的分布函数为

$$F^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

又若 X 具有概率密度 f , 则 (X_1, X_2, \dots, X_n) 的概率密度为

$$f^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

6.2 直方图和箱线图

直方图和箱线图的定义及画法略。

6.3 抽样分布

定义 6.2

定义 6.3 设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, $g(X_1, X_2, \dots, X_n)$ 是 X_1, X_2, \dots, X_n 的函数, 若 g 中不含未知参数, 则称 $g(X_1, X_2, \dots, X_n)$ 是一统计量。

因为 X_1, X_2, \dots, X_n 都是随机变量, 而统计量 $g(X_1, X_2, \dots, X_n)$ 是随机变量的函数, 因此统计量是一个随机变量. 设 x_1, x_2, \dots, x_n 是相应于样本 X_1, X_2, \dots, X_n 的样本值, 则称 $g(x_1, x_2, \dots, x_n)$ 是 $g(X_1, \dots, X_n)$ 的观察值。

下面列出几个常用的统计量, 设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, x_1, x_2, \dots, x_n 是这一样本的观察值, 定义

样本平均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$$

样本标准差

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

样本 k 阶（原点）矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \dots$$

样本 k 阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, \quad k = 2, 3, \dots$$

它们的观察值分别为

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} (\sum_{i=1}^n x_i^2 - n\bar{x}^2)$$

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$a_k = \frac{1}{n} \sum_{i=1}^n x_i^k, \quad k = 1, 2, \dots$$

$$b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k, \quad k = 2, 3, \dots$$

定义 6.4 (经验分布函数) 与总体分布函数 $F(x)$ 相应的统计量——经验分布函数的做法为：设 X_1, X_2, \dots, X_n 是总体 F 的一个样本，用 $S(x), -\infty < x < \infty$ 表示 X_1, X_2, \dots, X_n 中不大于 x 的随机变量的个数.定义经验分布函数 $F_n(x)$ 为

$$F_n(x) = \frac{1}{n} S(x), \quad -\infty < x < \infty$$

定义 6.5 (χ^2 分布) 设 X_1, X_2, \dots, X_n 是来自总体 $N(0, 1)$ 的样本，则称统计量

$$\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$$

服从自由度为 n 的 χ^2 分布，记为 $\chi^2 \sim \chi^2(n)$.此处自由度是指上式右端包含的独立变量的个数。




图 1: $\chi^2(n)$ 分布的概率密度图

$\chi^2(n)$ 分布的概率密度为

$$f(y) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} y^{n/2-1} e^{-y/2}, & y > 0 \\ 0, & \text{其他} \end{cases}$$

$f(y)$ 的图形如图1所示。

定理 6.1 χ^2 分布的性质:

χ^2 分布的可加性 设 $\chi_1^2 \sim \chi^2(n_1)$, $\chi_2^2 \sim \chi^2(n_2)$, 并且 χ_1^2, χ_2^2 相互独立, 则有

$$\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$$

χ^2 分布的数学期望和方差 若 $\chi^2 \sim \chi^2(n)$, 则有

$$E(\chi^2) = n, \quad D(\chi^2) = 2n$$

χ^2 分布的上分位点 对于给定的正数 $\alpha, 0 < \alpha < 1$, 满足条件

$$P\{\chi^2 > \chi_\alpha^2(n)\} = \int_{\chi_\alpha^2(n)}^{\infty} f(y) dy = \alpha$$

的点 $\chi_\alpha^2(n)$ 就是 $\chi^2(n)$ 分布的上 α 分位点。

定义 6.6 (t分布) 设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 X, Y 相互独立, 则称随机变量

$$t = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 t 分布.记为 $t \sim t(n)$.

t 分布又称学生氏(Student)分布. $t(n)$ 分布的概率密度函数为

$$h(t) = \frac{\Gamma[(n+1)/2]}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}, \quad -\infty < t < \infty$$




图 2: t 分布的概率密度图

定义 6.7 (t分布的上分位点) 对于给定的 $\alpha, 0 < \alpha < 1$, 满足条件

$$P\{t > t_\alpha(n)\} = \int_{t_\alpha(n)}^{\infty} h(t) dt = \alpha$$

的点 $t_{\alpha}(n)$ 就是 $t(n)$ 分布的上 α 分位点。由定义及 $h(t)$ 图形的对称性可知

$$t_{1-\alpha}(n) = -t_{\alpha}(n)$$

定义 6.8 (F分布) 设 $U \sim \chi^2(n_1), V \sim \chi^2(n_2)$, 且 U, V 相互独立, 则称随机变量

$$F = \frac{U/n_1}{V/n_2}$$

服从自由度为 (n_1, n_2) 的 F 分布, 记为 $F \sim F(n_1, n_2)$.

$F(n_1, n_2)$ 分布的概率密度为

$$\psi(y) = \begin{cases} \frac{\Gamma[(n_1+n_2)/2](n_1/n_2)^{n_1/2} y^{(n_1/2)-1}}{\Gamma(n_1/2)\Gamma(n_2/2)[1+(n_1y/n_2)]^{(n_1+n_2)/2}}, & y > 0, \\ 0, & \text{其他} \end{cases}$$

$\psi(y)$ 的图形如下图所示




图 3: F 分布的概率密度图

由定义可知, 若 $F \sim F(n_1, n_2)$, 则

$$\frac{1}{F} \sim F(n_2, n_1)$$

定义 6.9 (F分布的上分位点) 对于给定的 $\alpha, 0 < \alpha < 1$, 满足条件

$$P\{F > F_{\alpha}(n_1, n_2)\} = \int_{F_{\alpha}(n_1, n_2)}^{\infty} \psi(y) dy = \alpha$$

的点 $F_{\alpha}(n_1, n_2)$ 就是 $F(n_1, n_2)$ 分布的上 α 分位点。

F 分布的上 α 分布有如下的重要性质:

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$$

定理 6.2 设 X_1, X_2, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, \bar{X} 是样本均值, 则有

$$\bar{X} \sim N(\mu, \sigma^2/n)$$

定理 6.3 设 X_1, X_2, \dots, X_n 是来自总体 $N(\mu, \sigma^2)$ 的样本, \bar{X}, S^2 分别是样本均值和样本方差, 则有

$$1^\circ \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1);$$

2° \bar{X} 与 S^2 相互独立

定理 6.4 设 X_1, X_2, \dots, X_n 是来自总体 $N(\mu, \sigma^2)$ 的样本, \bar{X}, S^2 分别是样本均值和样本方差, 则有

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

定理 6.5 设 X_1, X_2, \dots, X_{n_1} 与 Y_1, Y_2, \dots, Y_{n_2} 分别是来自正态总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的样本, 且这

两个样本相互独立. 设 $\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i, \bar{Y} = \frac{1}{n_2} \sum_{i=1}^{n_2} Y_i$ 分别是这两个样本的样本均值; $S_1^2 = \frac{1}{n_1-1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2$

, $S_2^2 = \frac{1}{n_2-1} \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2$ 分别是这两个样本的样本方差, 则有

$$1^\circ \frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1-1, n_2-1);$$

2° 当 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 时,

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2),$$

其中

$$S_w^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}, \quad S_w = \sqrt{S_w^2}$$

7 参数估计

7.1 点估计

定义 7.1 点估计问题的一般提法如下：设总体 X 的分布函数 $F(x; \theta)$ 的形式为已知， θ 是待估参数。 X_1, X_2, \dots, X_n 是 X 的一个样本， x_1, x_2, \dots, x_n 是相应的一个样本值。点估计问题就是要构造一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ ，用它的观察值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 作为未知参数 θ 的近似值。称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的估计量，称 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的估计值。在不致混淆的情况下统称估计量和估计值为估计。

定义 7.2 (矩估计法) 设 X 为连续型随机变量，其概率密度为 $f(x; \theta_1, \theta_2, \dots, \theta_k)$ ，或 X 为离散型随机变量，其分布律为 $P\{X = x\} = p(x; \theta_1, \theta_2, \dots, \theta_k)$ ，其中 $\theta_1, \theta_2, \dots, \theta_k$ 为待估参数， X_1, X_2, \dots, X_n 是来自 X 的样本。假设总体 X 的前 k 阶矩

$$\mu_l = E(X^l) = \int_{-\infty}^{\infty} x^l f(x; \theta_1, \theta_2, \dots, \theta_k) dx \quad X \text{ 为连续型}$$

或

$$\mu_l = E(X^l) = \sum_{x \in R_X} x^l p(x; \theta_1, \theta_2, \dots, \theta_k) \quad X \text{ 为离散型}$$

($l = 1, 2, \dots, k$, 其中 R_X 是 X 可能取值的范围) 存在。一般来说，它们是 $\theta_1, \theta_2, \dots, \theta_k$ 的函数。基于样本矩

$$A_l = \frac{1}{n} \sum_{i=1}^n X_i^l$$

依概率收敛于相应的总体矩 μ_l ($l = 1, 2, \dots, k$)，样本矩的连续函数依概率收敛于相应的总体矩的连续函数，我们就用样本矩作为相应的总体矩的估计量，而以样本矩的连续函数作为相应的总体矩的连续函数的估计量。这种估计方法称为矩估计法。

矩估计法的具体做法如下：设

$$\begin{cases} \mu_1 = \mu_1(\theta_1, \theta_2, \dots, \theta_k), \\ \mu_2 = \mu_2(\theta_1, \theta_2, \dots, \theta_k), \\ \vdots \\ \mu_k = \mu_k(\theta_1, \theta_2, \dots, \theta_k), \end{cases}$$

这是一个包含 k 个未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的联立方程组。一般来说，可以从中解出 $\theta_1, \theta_2, \dots, \theta_k$ ，得到

$$\begin{cases} \theta_1 = \theta_1(\mu_1, \mu_2, \dots, \mu_k), \\ \theta_2 = \theta_2(\mu_1, \mu_2, \dots, \mu_k), \\ \vdots \\ \theta_k = \theta_k(\mu_1, \mu_2, \dots, \mu_k), \end{cases}$$

以 A_i 分别代替上式中的 $\mu_i, i = 1, 2, \dots, k$ ，就以

$$\hat{\theta}_i = \theta_i(A_1, A_2, \dots, A_k), i = 1, 2, \dots, k$$

分别作为 $\theta_i, i = 1, 2, \dots, k$ 的估计量, 这种估计量称为矩估计量, 矩估计量的观察值称为矩估计值.

定义 7.3 (最大似然估计法) 若总体 X 属离散型, 其分布律 $P\{X = x\} = p(x; \theta), \theta \in \Theta$ 的形式为已知, θ 为待估参数, Θ 是 θ 可能取值的范围. 设 X_1, X_2, \dots, X_n 是来自 X 的样本, 则 X_1, X_2, \dots, X_n 的联合分布律为

$$\prod_{i=1}^n p(x_i; \theta)$$

又设 x_1, x_2, \dots, x_n 是相应于样本 X_1, X_2, \dots, X_n 的一个样本值. 易知样本 X_1, X_2, \dots, X_n 取到观察值 x_1, x_2, \dots, x_n 的概率, 亦即事件 $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$ 发生的概率为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta), \theta \in \Theta$$

这一概率随 θ 的取值而变化, 它是 θ 的函数, $L(\theta)$ 称为样本的似然函数. (注意, 这里 x_1, x_2, \dots, x_n 是已知的样本值, 它们都是常数).

由费希尔引进的最大似然估计法, 就是固定样本观察值 x_1, x_2, \dots, x_n , 在 θ 取值的可能范围 Θ 内挑选使似然函数 $L(x_1, x_2, \dots, x_n; \theta)$ 达到最大的参数值 $\hat{\theta}$, 作为参数 θ 的估计值. 即取 $\hat{\theta}$ 使

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

这样得到的 $\hat{\theta}$ 与样本值 x_1, x_2, \dots, x_n 有关, 常记为 $\hat{\theta}(x_1, x_2, \dots, x_n)$, 称为参数 θ 的最大似然估计值, 而相应的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为参数 θ 的最大似然估计量.

若总体 X 属连续型, 其概率密度 $f(x; \theta), \theta \in \Theta$ 的形式已知, θ 为待估参数, Θ 是 θ 可能取值的范围. 设 X_1, X_2, \dots, X_n 是来自 X 的样本, 则 X_1, X_2, \dots, X_n 的联合密度为

$$\prod_{i=1}^n f(x_i, \theta)$$

设 x_1, x_2, \dots, x_n 是相应于样本 X_1, X_2, \dots, X_n 的一个样本值, 则随机点 (X_1, X_2, \dots, X_n) 落在点 (x_1, x_2, \dots, x_n) 的邻域 (边长分别为 dx_1, dx_2, \dots, dx_n 的 n 维立方体) 内的概率近似地为

$$\prod_{i=1}^n f(x_i; \theta) dx_i \quad (1)$$

其值随 θ 的取值而变化. 与离散型的情况一样, 取 θ 的估计值 $\hat{\theta}$ 使概率(1)取到最大值, 但因因子 $\prod_{i=1}^n dx_i$ 不随 θ 而变, 故只考虑函数

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

的最大值. 这里 $L(\theta)$ 称为样本的似然函数. 若

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

则称 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的最大似然估计值, 称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的最大似然估计量。

这样, 确定最大似然估计量的问题就归结为微分学中的求最大值的问题了。

在很多情况下, $p(x; \theta)$ 和 $f(x; \theta)$ 关于 θ 可微, 这时 $\hat{\theta}$ 常可从方程

$$\frac{d}{d\theta} L(\theta) = 0$$

解得. 又因 $L(\theta)$ 和 $\ln L(\theta)$ 在同一 θ 处取到极值, 因此, θ 的最大似然估计 $\hat{\theta}$ 也可以从方程

$$\frac{d}{d\theta} \ln L(\theta) = 0 \quad (2)$$

求得, 而从后一方程求解往往比较方便。(2)称为对数似然方程。

最大似然估计法也适用于分布中含多个未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的情况。这时, 似然函数 L 是这些未知参数的函数. 分别令

$$\frac{\partial}{\partial \theta_i} L = 0, i = 1, 2, \dots, k$$

或令

$$\frac{\partial}{\partial \theta_i} \ln L = 0, i = 1, 2, \dots, k \quad (3)$$

解上述由 k 个方程组成的方程组, 即可得到各未知参数 $\theta_i (i = 1, 2, \dots, k)$ 的最大似然估计值 $\hat{\theta}_i$. (3)称为对数似然方程组。

定理 7.1 最大似然估计具有下述性质: 设 θ 的函数 $u = u(\theta)$, $\theta \in \Theta$ 具有单值反函数 $\theta = \theta(u)$, $u \in \mathfrak{U}$. 又假设 $\hat{\theta}$ 是 X 的概率分布中参数 θ 的最大似然估计, 则 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的最大似然估计。这一性质称为最大似然估计的不变性。

事实上, 因为 $\hat{\theta}$ 是 θ 的最大似然估计, 于是有

$$L(x_1, x_2, \dots, x_n; \theta) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n, \theta)$$

其中 x_1, x_2, \dots, x_n 是 X 的一个样本值, 考虑到 $\hat{u} = u(\hat{\theta})$, 且有 $\hat{\theta} = \theta(\hat{u})$, 上式可写成

$$L(x_1, x_2, \dots, x_n; \theta(\hat{u})) = \max_{u \in \mathfrak{U}} L(x_1, x_2, \dots, x_n; \theta(u))$$

这就证明了 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的最大似然估计。

当总体分布含有多个未知参数时, 也具有上述性质。例如 σ^2 的最大似然估计为

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

函数 $u = u(\sigma^2) = \sqrt{\sigma^2}$ 有单值反函数 $\sigma^2 = u^2 (u \geq 0)$, 根据上述性质, 得到标准差 σ 的最大似然估计为

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

7.2 估计量的评选标准

8 假设检验

8.1 假设检验

9 方差分析及回归分析

9.1 单因素试验的方差分析